

‘진짜 회사를 운영하는 AI’는 아직 하나의 점수가 아니다

실제 benchmark artifact 3종 · 9개 episode decode · Qwen 0.5B 실행 결과

하나의 점수 대신, 누적 capability ladder가 필요하다

EVIDENCE

검사한 최고 공개 artifact는 L3 surface와 L4 일부까지. L5 real outcome은 없음.

1

Tool call

arguments · auth

2

Bounded workflow

multi-step · final state

3

Cross-functional

multi-app · coordination

4

Judgment

uncertainty · policy

5

Company outcome

revenue · trust · harm

문헌이 아니라 파일을 열어 확인했다

EVIDENCE 세 artifact에서 실제 row/episode 3개씩을 보존 schema로 변환했다.

175

TheAgentCompany
task directories

4,280

CRMArenaPro
unique queries

9 / 9

decoded episodes
schema-valid

세 후보는 서로 다른 것을 측정한다

EVIDENCE 점수는 setting이 달라 직접 서열화하지 않는다.

Artifact	Actual schema	State / action	Reset	License	Cannot prove
CRMArenaPro	JSON task row	Salesforce query / respond	logical only	CC BY-NC 4.0	mutable workflow; delayed outcome
TheAgentCompany	task dir + evaluator	5 apps + shell/browser	task image init	MIT code	real firm history; economic outcome
Gaia2	Parquet → JSON scenario	apps + scheduled events	scenario re-import	CC BY 4.0 / MIT	prospective company outcome

‘episode’는 prompt 한 줄이 아니라 계약이다

EVIDENCE 원본 payload는 보존하고, 비교 가능한 최소 필드만 정규화한다.

- 01 ————— **Task** objective · policy · provenance
- 02 ————— **State** initial observation · hidden state refs
- 03 ————— **Action** typed space · authority boundary
- 04 ————— **Reward** grader · terminal condition
- 05 ————— **Replay** reset semantics · source revision

Qwen SFT는 형식을 고쳤지만 판단은 못 고쳤다

EVIDENCE 12-step LoRA · 5.40 s · 1.281 GiB peak · \$0

Base

|

Post-SFT



Parse validity 0% → 100%



No hard failure 0% → 100%

Exact decision 0% → 0%

0% → 100%

parse validity

0% → 0%

held-out exact decision

해석: format recovery only

점수를 올리는 데이터는 여섯 가지 역할로 분리된다

SFT trace

input → demonstrated action

limit → coverage ceiling

Preference

input → ranked rollouts

limit → causal ambiguity

Verifier

input → score / reward

limit → proxy hacking

Outcome

input → delayed consequence

limit → confounding

Rollout

input → state transitions

limit → cost / mismatch

RLVR

input → verified reward update

limit → variance / exploit

NOT YET RLVR는 grader 신뢰성과 reward variance가 생긴 뒤에만.

사업은 'benchmark 공급자'와 '새 category'로 갈린다

HYPOTHESIS 두 경로를 동시에 넓히지 말고, 30일 증거로 선택한다.

A. 기존 점수 개선

adapter · rollout · verifier

빠른 demo / 약한 moat

Kill: 고객이 public score만 원하고 지불하지 않음

B. company-operation category

rights · replay · outcome

강한 wedge / 높은 validity cost

Kill: retrieval baseline tie 또는 outcome closure 실패

30일 안에 thesis가 아니라 prospective ranking을 검증한다

KILL GATE

simple baseline tie · unstable ranking · no outcome · no held-out transfer

Freeze

task · rights · cutoff

Capture


≥20 shadow episodes

Compare

human / generic / RAG / env

Close

delayed outcome · transfer



새 benchmark를 선언하지 말고, 한 decision environment를 반증하자

승인 요청: rights-valid shadow capture 설계 · paid compute는 별도 승인